



UNIVERSIDAD DE GRANADA

VISIÓN POR COMPUTADOR
GRADO EN INGENIERÍA INFORMÁTICA

TRABAJO 2

CUESTIONES DE TEORÍA

Autor

Vladislav Nikolov Vasilev

Rama

Computación y Sistemas Inteligentes



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

CURSO 2019-2020

Índice

Ejercicio 1	2
Ejercicio 2	2
Ejercicio 3	4
Ejercicio 4	4
Ejercicio 5	5
Ejercicio 6	5
Ejercicio 7	6
Ejercicio 8	7
Ejercicio 9	7
Ejercicio 10	8
Ejercicio 11	8
Ejercicio 12	9
Ejercicio 13	9
Ejercicio 14	9
Ejercicio 15	10
Referencias	11

Ejercicio 1

Identifique las semejanzas y diferencias entre los problemas de: a) clasificación de imágenes; b) detección de objetos; c) segmentación de imágenes; d) segmentación de instancias.

Solución

La clasificación de imágenes consiste en asignar una clase a una imagen de entrada. La detección de objetos permite determinar qué objetos hay en una imagen y localizándolos dentro de ésta, de forma que se muestra una *bounding box* a su alrededor y se identifica de qué clase son los objetos detectados. La segmentación de imágenes consiste en clasificar cada píxel de una imagen, asignándole una u otra clase. La segmentación de instancias permite distinguir entre las distintas instancias de los objetos encontrados dentro de la imagen, de forma que, a pesar de que puedan pertenecer a la misma clase, sean tratados como entidades diferentes de una misma clase.

Como se puede ver, cada problema tiene sus peculiaridades, ya que en cada uno se persigue resolver cosas diferentes. Sin embargo, existen ciertas similitudes entre ellos. Por ejemplo, tanto en la clasificación de imágenes como en la detección de objetos se predice una clase (en el primer caso, es el problema principal, mientras que en el segundo se predice de qué tipo es el objeto detectado dentro de los tipos conocidos). La segmentación de imágenes parece una mezcla de la detección de objetos y clasificación, ya que se trata de una clasificación de más bajo nivel (píxel a píxel), y en dicho proceso se detectan objetos de distintas clases. La segmentación de instancias es un paso más allá de la detección de objetos, ya que permite detectar objetos dentro de la imagen al mismo nivel que la segmentación de imágenes (a nivel de píxel) y permite distinguir entre las distintas instancias de los objetos de una misma clase. Por tanto, es una sofisticación de la detección de objetos.

Ejercicio 2

¿Cuál es la técnica de búsqueda estándar para la detección de objetos en una imagen? Identifique pros y contras de la misma e indique posibles soluciones para estos últimos.

Solución

La técnica estándar para detectar objetos en imágenes es la *sliding window* o **ventana deslizante**. Esta técnica consiste en pasar un rectángulo de dimensiones fijas por la imagen obteniendo una ventana. Dicha ventana es pasada luego a un

clasificador, el cuál predice si está o no el objeto a detectar dentro de esa ventana. Ese clasificador debe haber sido entrenado previamente para detectar objetos de la clase a buscar.

La principal ventaja es que una técnica que descompone un problema relativamente complejo, que es la detección de objetos dentro de imágenes, en un problema más simple de clasificación (decir si está o no el objeto). Además es una técnica conceptualmente sencilla, con lo cuál es relativamente fácil de implementar. Sin embargo, como toda técnica, tiene sus desventajas:

- **Coste computacional alto.** Esta técnica es costosa, ya que se deben clasificar muchas ventanas de una imagen, y además, los desplazamientos de la ventana por la imagen no pueden ser pequeños, ya que si lo fuesen, la técnica sería totalmente inviable, porque se tardaría demasiado tiempo en procesar la imagen completa.
- **Detectar objetos de diferentes tamaños.** Este es uno de los problemas más básicos. Si el tamaño de la ventana es demasiado pequeño, a lo mejor se pierden algunos de los objetos de la imagen, ya que son demasiado grandes como para ser detectados. Para ello, se puede o bien pasar ventanas de distinto tamaño por la imagen, o bien se puede construir un espacio de escalas de la imagen, utilizando por ejemplo la pirámide Gaussiana, y pasar la misma ventana por todas las imágenes de la escala.
- **Objetos con distintos ratios de aspecto.** Este problema se da cuando un objeto aparece con distintas proporciones, no adaptándose por tanto a la forma de la ventana que se está pasando. Para ello, se pueden pasar ventanas con distintos ratios de aspecto. Esto hace que el coste computacional sea mayor, ya que, para cada imagen de la escala se deben pasar v ventanas.
- **Múltiples respuestas de un objeto.** Un mismo objeto puede ser detectado por varias ventanas, con lo cuál ofrece más de una respuesta. Como solo nos interesa una, podemos realizar la **supresión de no máximos**, quedándonos con solo una de las ventanas.
- **Solapamiento de objetos.** Puede suceder que dos o más objetos estén solapados, es decir, que alguno o algunos de ellos sea parcialmente visible. La única solución es que el clasificador sea lo bastante robusto y haya sido entrenado con ejemplos así, de forma que también pueda detectar objetos de este tipo.

Ejercicio 3

Considere la aproximación que extrae una serie de características en cada píxel de la imagen para decidir si hay contorno o no. Diga si existe algún paralelismo entre la forma de actuar de esta técnica y el algoritmo de Canny. En caso positivo identifique cuales son los elementos comunes y en que se diferencian los distintos.

Solución

Ejercicio 4

Tanto el descriptor de SIFT como HOG usan el mismo tipo de información de la imagen pero en contextos distintos. Diga en que se parecen y en que son distintos estos descriptores. Explique para que es útil cada uno de ellos.

Solución

Ambos descriptores utilizan el cálculo del gradiente para extraer información de la imagen. Además, ambos tienen mecanismos para ser invariantes a los cambios de iluminación. No obstante, existen una serie de diferencias entre ambos.

Los descriptores que extrae SIFT son invariantes a otros factores, como por ejemplo la escala y la rotación, cosa que no pasa con los obtenidos por HOG, ya que estos son sensibles a las rotaciones (si se rota la imagen, los descriptores son diferentes). Otra diferencia es el uso: SIFT se suele utilizar para la extracción de regiones relevantes de una imagen, mientras que HOG se suele utilizar para la detección de objetos en imágenes, utilizando junto con él un clasificador.

La utilidad de SIFT viene de que, como su nombre indica, extrae características que son invariantes a una serie de factores, lo cuál lo hace ideal para la detección de regiones relevantes en imágenes, las cuáles tienen una serie de usos, como por ejemplo clasificación de imágenes. Por otro lado, la información que extrae HOG puede ser fácilmente utilizada para entrenar un clasificador, y se puede combinar junto con la ventana deslizante para recorrer una imagen, obtener los descriptores de la ventana y ver si el clasificador detecta o no un objeto en la región donde se sitúa la ventana.

Ejercicio 5

Observando el funcionamiento global de una CNN, identifique que dos procesos fundamentales definen lo que se realiza en un pase hacia delante de una imagen por la red. Asocie las capas que conozca a cada uno de ellos.

Solución

El primer proceso fundamental es la **extracción de características**. Mediante este proceso se puede extraer información relevante sobre la imagen de entrada. En este proceso intervienen toda una serie de capas, como las capas convolucionales, las cuáles realizan transformaciones sobre la imagen de entrada; las capas de activación, las cuáles introducen alguna función no lineal sobre las salidas de las capas convoluciones, como por ejemplo la función ReLU; y las capas de *pooling*, las cuáles realizan una reducción o aumento del tamaño de la imagen. También se pueden utilizar otras capas en este proceso las cuáles sirven para regularizar el modelo, como por ejemplo las capas de Dropout o de Batch Normalization. De esta forma, se puede llegar a evitar el sobreajuste que se pueda producir en el modelo.

El segundo proceso fundamental es la **predicción**, la cuál utiliza la información extraída en el proceso anterior para proporcionar algún tipo de información de salida. Por ejemplo, se puede predecir a qué clase pertenece una imagen dada. En esta parte se utilizan normalmente capas totalmente conectadas con una función de activación determinada en la última capa. En el ejemplo de clasificación anterior se utilizaría la función **softmax**, la cuál da un vector de probabilidades para cada una de las clases.

Ejercicio 6

Se ha visto que el aumento de la profundidad de una CNN es un factor muy relevante para la extracción de características en problemas complejos, sin embargo este enfoque añade nuevos problemas. Identifique cuales son y qué soluciones conoce para superarlos.

Solución

Al aumentar la profundidad de la red, se pueden extraer mejores características de la imagen, y por ende, se pueden aprender funciones más complejas. Sin embargo, existe un problema con este enfoque, y es que llega un punto en el que la función que se aprende se empieza a pegar demasiado a los datos de entrenamiento, y por tanto se produce sobreajuste. Para evitarlo, se pueden introducir capas de regularización,

como por ejemplo **Batch Normalization**, **Dropout** o haciendo un *early-stopping*, de forma que se pare de entrenar antes de que se produzca sobreajuste.

Otro problema que nos encontramos al aumentar la profundidad es que llega un punto en el que el error propagado por el algoritmo de **Back Propagation** es 0, con lo cuál no llega nada a las primeras capas y no se produce un ajuste de los pesos en función del gradiente. Este problema tiene distintas soluciones, como por ejemplo modificar la red de forma la arquitectura no sea secuencial, haciendo que una capa no esté conectada solamente con la siguiente, si no con otras, como por ejemplo se hace en la red residual **ResNet** [1]; o también introduciendo más de un clasificador en la red, como por ejemplo en **GoogLeNet** [3], de forma que el gradiente no pierda su intensidad.

Ejercicio 7

Existe actualmente alternativas de interés al aumento de la profundidad para el diseño de CNN. En caso afirmativo diga cuál/es y como son.

Solución

En la actualidad, existen ciertas alternativas a la hora de crear la arquitectura de una CNN que tienen como objetivo conseguir mejores resultados sin aumentar necesariamente la profundidad de la red.

- **Redes densas.** [2] En estas redes se introduce como mejora que cada capa está conectada con todas las siguientes, de forma que esto permite solucionar en parte el problema de que se pierda el gradiente debido a la profundidad. Además de eso, al estar conectadas las capas de esta forma, se reutilizan las características, de forma que el número de parámetros de la red disminuye y es mucho más fácil de entrenar.
- **Skip connections.** Con esta mejora, se hace que la salida de una capa no solo pase a la siguiente, si no a alguna capa situada más adelante. No es una versión tan particular como el caso anterior, ya que aquí la salida de una capa no está conectada con todas las capas siguientes. Esta mejora también ayuda a propagar mejor el gradiente. Se utiliza por ejemplo en las **ResNets**.
- **Aumentar la cardinalidad.** [4] La cardinalidad se refiere al número de conjuntos de transformaciones que realiza un módulo. De esta forma, al aumentar la cardinalidad, el conjunto de operaciones se hace mayor, y por tanto la entrada de una capa no es el resultado de solo una convolución con alguna activación y algún *pooling*, si no que es un ensamblado de la salida que

produce cada una de las transformaciones del conjunto. Con esto se pueden conseguir extraer características más complejas, y en general, mejorar la *accuracy* de la red.

Ejercicio 8

Considere una aproximación clásica al reconocimiento de escenas en donde extraemos de la imagen un vector de características y lo usamos para decidir la clase de cada imagen. Compare este procedimiento con el uso de una CNN para el mismo problema. ¿Hay conexión entre ambas aproximaciones? En caso afirmativo indique en que parecen y en que son distintas.

Solución

En ambos enfoques es necesario extraer primero las características de la imagen mediante algún tipo de técnica para poder clasificarla luego utilizando un clasificador. La similitud acaba aquí, ya que la forma de hacerlo en cada caso es diferente:

- En el caso clásico, la extracción de características y la clasificación se hacen de forma separada. Es decir, primero el ingeniero debe determinar cuál es la mejor forma de extraer características de las imágenes para el problema que tiene y, una vez las ha extraído, debe entrenar un clasificador.
- En las CNN, todo el proceso es *end-to-end*. La extracción de características la realiza la propia red sin ninguna intervención humana, además de que se encarga ésta de realizar la clasificación según las características extraídas. Al entrenar la red, se entrena tanto la parte de extracción de características como el clasificador que tiene.

Ejercicio 9

¿Cómo evoluciona el campo receptivo de las neuronas de una CNN con la profundidad de la capas? ¿Se solapan los campos receptivos de las distintas neuronas de una misma profundidad? ¿Es este hecho algo positivo o negativo de cara a un mejor funcionamiento?

Solución

El campo receptivo va aumentando a medida que aumenta la profundidad de

la CNN. Esto se debe a que, a medida que va aumentando la profundidad de la red, se van utilizando regiones cada vez mayores de la imagen de entrada de la red. Por ejemplo, en la primera capa se extraen características de más bajo nivel. En el siguiente nivel se utilizan las características extraídas anteriormente, combinándolas entre ellas para obtener características de más alto nivel, y así sucesivamente. Como se van combinando características, se combina información extraída de distintas partes de la imagen, con lo cuál, a más profundidad, mayor región de la imagen es utilizada.

Los campos receptivos de las distintas neuronas de una misma profundidad se solapan cuando se utiliza un **stride** menor al tamaño del *kernel* utilizado. Si se utiliza un **stride** mayor, no se producirá ningún solapamiento. Que se solapen los campos receptivos es algo bueno, ya que al aparecer la información extraída de una región varias veces, se puede combinar con información muy distinta, de forma que se pueden llegar a obtener mejores características en general que si no se solapasen, ya que dicha información aparecería solo una vez, y puede que la forma de combinarla no fuese la mejor. Además, este solapamiento imita al funcionamiento de los nervios ópticos, ya que se sabe que también se produce solapamiento de las conexiones nerviosas.

Ejercicio 10

¿Qué operación es central en el proceso de aprendizaje y optimización de una CNN?

Solución

Ejercicio 11

Compare los modelos de detección de objetos basados en aproximaciones clásicas y los basados en CNN y diga que dos procesos comunes a ambos aproximaciones han sido muy mejorados en los modelos CNN. Indique cómo.

Solución

Ejercicio 12

Es posible construir arquitecturas CNN que sean independientes de las dimensiones de la imagen de entrada. En caso afirmativo diga cómo hacerlo y cómo interpretar la salida.

Solución

Ejercicio 13

Suponga que entrenamos una arquitectura Lenet-5 para clasificar imágenes 128×128 de 5 clases distintas. Diga que cambios deberían de hacerse en la arquitectura del modelo para que se capaz de detectar las zonas de la imagen donde aparecen alguno de los objetos con los que fue entrenada.

Solución

Ejercicio 14

Argumente por qué la transformación de un tensor de dimensiones $128 \times 32 \times 32$ en otro de dimensiones $256 \times 16 \times 16$, usando una convolución 3×3 con $\text{stride}=2$, tiene sentido que pueda ser aproximada por una secuencia de tres convoluciones: convolución 1×1 + convolución 3×3 + convolución 1×1 . Diga también qué papel juegan cada una de las tres convoluciones.

Solución

Antes de nada, vamos a ver qué es lo que haría cada una de las operaciones en el segundo caso:

- La primera convolución 1×1 reduciría la profundidad del tensor, de forma que se reduciría la dimensionalidad.
- La convolución 3×3 sería igual que la del caso base: tendría $\text{stride} = 2$ y se encargaría de extraer las características del tensor, reduciendo en el proceso su anchura y altura, pero conservando la profundidad anterior.
- La segunda convolución 1×1 aumentaría la profundidad del tensor de nuevo, haciendo que tenga tamaño 256.

Esta transformación aproxima a la primera la siguiente forma. En la primera convolución se reduce la dimensionalidad, y por tanto, se selecciona un conjunto de las características de alguna manera. Si la red ha sido bien entrenada, se debería tener aproximadamente la misma información en ambos casos antes de realizar la convolución 3×3 , solo que en el segundo se usarían menos dimensiones. Adicionalmente, la convolución 1×1 debería ser capaz de representar la misma información que la que se ha obtenido como resultado de la operación anterior, solo que utilizando una mayor profundidad. Por tanto, las piezas clave para que el resultado final sea aproximadamente el mismo es la capacidad que tengan las convoluciones 1×1 en resumir y en ampliar las características.

Ejercicio 15

Identifique una propiedad técnica de los modelos CNN que permite pensar que podrían llegar a aproximar con precisión las características del modelo de visión humano, y que sin ella eso no sería posible. Explique bien su argumento.

Solución

Referencias

- [1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *CoRR*, abs/1512.03385, 2015.
- [2] Gao Huang, Zhuang Liu, and Kilian Q. Weinberger. Densely connected convolutional networks. *CoRR*, abs/1608.06993, 2016.
- [3] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott E. Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. *CoRR*, abs/1409.4842, 2014.
- [4] Saining Xie, Ross B. Girshick, Piotr Dollár, Zhuowen Tu, and Kaiming He. Aggregated residual transformations for deep neural networks. *CoRR*, abs/1611.05431, 2016.