



UNIVERSIDAD DE GRANADA

VISIÓN POR COMPUTADOR
GRADO EN INGENIERÍA INFORMÁTICA

PRÁCTICA 2

REDES NEURONALES CONVOLUCIONALES

Autor

Vladislav Nikolov Vasilev

Rama

Computación y Sistemas Inteligentes



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

CURSO 2019-2020

Índice

1. BASENET EN CIFAR100	2
2. MEJORA DEL MODELO	7
2.1. Normalización de los datos	8
2.2. Aumento de datos	11
2.3. Aumento de la profundidad de la red	16
2.4. Mejora extra: regularización mediante Dropout	20
2.5. Capas de normalización	25
2.6. Ajuste del modelo final	29
3. TRANSFERENCIA DE MODELOS Y AJUSTE FINO CON RESNET50 PARA LA BASE DE DATOS CALTECH-UCSD	32
3.1. ResNet50 como extractor de características	32
3.2. Ajuste fino de ResNet50	33
Referencias	34

1. BASENET EN CIFAR100

Antes de empezar con la traducción de la arquitectura proporcionada de *BaseNet*, hace falta establecer la forma de la entrada de la primera capa de la red. Esto es necesario, ya que el modelo necesita conocer dicho tamaño para poder ser compilado sin ningún tipo de error. Como las imágenes de *CIFAR100* tienen un tamaño de 32×32 píxeles, y tienen 3 canales, la dimensión de la entrada va a ser la siguiente:

```
1 # Tamaño de la entrada
2 input_shape = (32, 32, 3)
```

Una vez definida la forma de la entrada, ya se puede empezar a hacer la traducción a código. El resultado es el siguiente:

```
1 # Creacion del modelo
2 model = Sequential()
3 model.add(Conv2D(6, kernel_size=(5, 5), padding='valid',
4                 input_shape=input_shape))
5 model.add(Activation('relu'))
6 model.add(MaxPooling2D(pool_size=(2, 2)))
7
8 model.add(Conv2D(16, kernel_size=(5, 5), padding='valid'))
9 model.add(Activation('relu'))
10 model.add(MaxPooling2D(pool_size=(2, 2)))
11
12 model.add(Flatten())
13 model.add(Dense(units=50))
14 model.add(Activation('relu'))
15 model.add(Dense(units=25))
16 model.add(Activation('softmax'))
```

BaseNet es un modelo secuencial, así que empezamos indicando eso. A continuación, añadimos el primer módulo convolucional. Este se compone de una convolución 2D con un *kernel* de 5×5 , una función de activación no lineal (RELU en este caso) y un MaxPooling de tamaño 2×2 . El parámetro *padding = valid* de *Conv2D* indica que solo se tiene que aplicar la convolución allá donde se pueda ajustar el *kernel*; es decir, como en las regiones de los bordes no se puede, se van a ignorar estas zonas, lo cuál implica que la salida no va a tener el mismo tamaño que la entrada. Este módulo convolucional se repite otra vez. Después de eso, nos encontramos con las capas densas, las cuáles van a actuar como clasificador. La capa *Flatten* es necesario ponerla, ya que coge la salida de la anterior, la cuál es un bloque de tamaño $5 \times 5 \times 16$ (16 imágenes 5×5), y aplanando dicho bloque, convirtiéndolo en un vector de 400 características, el cuál sirve como entrada al modelo denso. La última capa, la de activación *softmax* es la que va a dar la salida, un vector de probabilidades para cada clase. En este caso, la salida va a ser un vector de 25 posiciones, ya que estamos en un problema donde hay 25 clases.

Con el modelo ya definido, y antes de compilarlo, tenemos que establecer algunas cosas más:

- **Optimizador.** El optimizador que se va a utilizar en este caso es el **SGD** o *Stochastic Gradient Descent*. Este es uno de los optimizadores más populares e importantes dentro del *machine learning*. Se utiliza mucho con redes neuronales, ya sean redes normales o profundas, y es conocido por su robustez y por ofrecer unos muy buenos resultados en general, además de ser bastante rápido a diferencia de otros optimizadores, como por ejemplo Adam. En este caso, se va a utilizar con los parámetros por defecto. Es decir, se tendrá un *learning rate* de 0.01, y no se utilizará momentum ni el momentum de Nesterov. Estos parámetros parecen razonables, ya que el *learning rate* no es ni demasiado pequeño ni demasiado grande. Además, como es un poco difícil ajustar el momento, se ha preferido no tocar este parámetro.
- **Tamaño del *batch*.** Otro elemento muy importante a determinar es el tamaño del *batch*, si bien no es necesario conocerlo en el momento en el que se compila el modelo. Para un problema como este, teniendo en cuenta que tenemos unos 11250 datos de entrenamiento, un tamaño de *batch* razonable es de 32. Este es un tamaño muy utilizado, ya que en general ofrece unos buenos resultados, ya que permite converger a buenos óptimos y hace que el modelo generalice bastante bien. Con un tamaño menor se estaría explorando demasiado el espacio, mientras que con uno mayor se estaría explotando una zona del espacio, lo cuál puede llegar a producir problemas, como que no se generalice demasiado bien [1], cosa que no nos interesa.
- **Número de épocas.** Éste es quizás el parámetro más difícil de decidir a priori, ya que no tenemos mucha información. Por tanto, ya que a medida que vayamos haciendo pruebas podremos ver las curvas de entrenamiento y validación, podremos decidir en función de éstas cuántas épocas debemos entrenar los modelos. Para empezar, podemos fijar unas 30 épocas, ya que parece un número razonable.

Con esto ya visto, podemos compilar nuestro modelo. Lo primero que tenemos que hacer es definir el optimizador. Como vamos a utilizar SGD, lo hacemos de la siguiente forma:

```
1 # Establecer optimizador a utilizar
2 optimizer = SGD()
```

Para compilar el modelo, lo haremos de la siguiente forma:

```
1 # Compilar el modelo
2 model.compile(
3     loss=keras.losses.categorical_crossentropy,
```

```

4     optimizer=optimizer,
5     metrics=['accuracy']
6 )

```

Como estamos en un problema de clasificación y la salida que va a dar el modelo es un vector de probabilidades para múltiples clases, especificamos que la función de pérdida que se utilizará es la entropía cruzada o *Categorical Cross-Entropy*, la cuál es muy utilizada en problemas de clasificación para múltiples clases. Especificamos también cuál será el optimizador a utilizar, e indicamos que la métrica que nos interesa es la precisión o *accuracy*, que representa la proporción de aciertos sobre el número total de elementos. Existen muchas otras métricas que se pueden utilizar, pero la *accuracy* es la más sencilla de entender.

Con el modelo ya compilado, podemos visualizarlo de la siguiente forma:

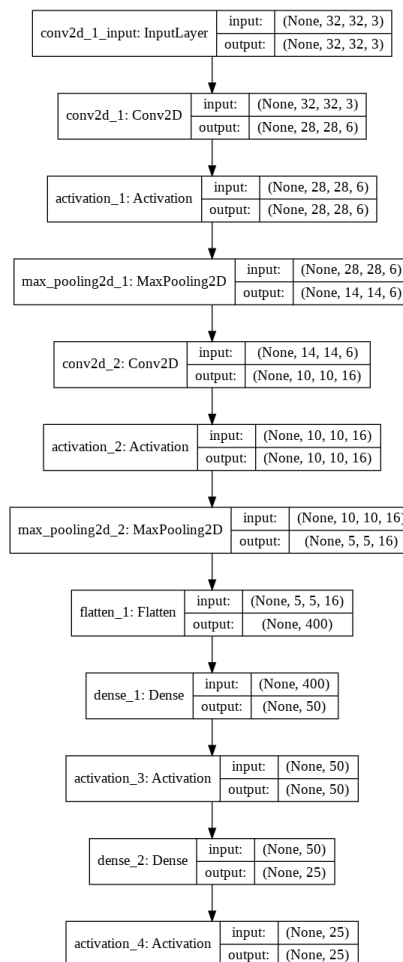


Figura 1: Esquema que representa el modelo *BaseNet*.

Aquí es donde podemos ver mejor la estructura del modelo. Se puede ver de forma más clara que antes la estructura secuencial que tiene, además de cada una de las capas y de los tamaños de las entradas y de las salidas de éstas.

Teniendo el modelo ya construido y compilado, para hacernos una idea de como de bueno es, podemos entrenarlo y probarlo con el conjunto de test. Es muy importante, antes de empezar, guardar los pesos que tiene el modelo. De esta forma, podremos restablecerlos posteriormente, para poder reentrenar el modelo. Para guardar los pesos, podemos hacerlo de la siguiente forma:

```
1 # Guardar los pesos iniciales del modelo
2 weights = model.get_weights()
```

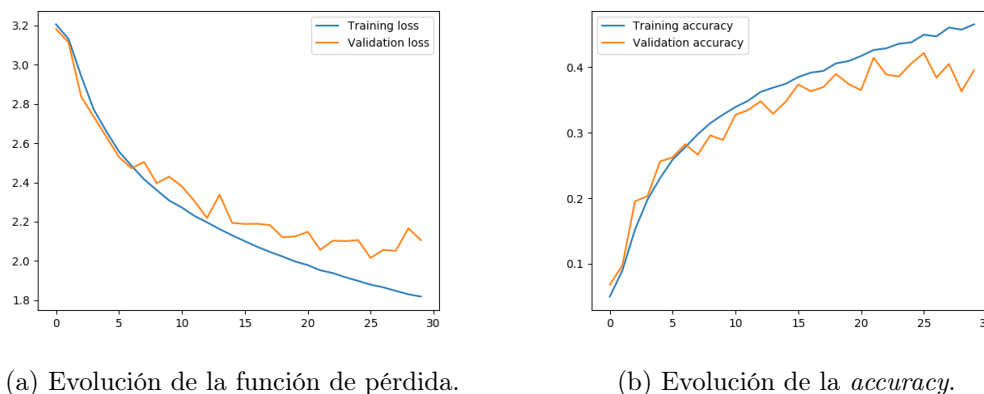
Ahora ya podemos proceder al entrenamiento. Es muy importante destacar que, con los datos de entrenamiento de los que disponemos, solo se tiene que entrenar con el 90 % de éstos; el 10 % restante se tiene que dejar para validar el modelo, y de esta forma poder obtener unas gráficas para el error y la *accuracy* en los conjuntos de entrenamiento y de validación. Estos valores que se obtienen para el conjunto de validación son, en general, una buena aproximación de lo que se puede obtener en el conjunto de test, si la muestra es lo suficientemente representativa de la población total, claro está.

Para entrenar el modelo, lo hacemos de la siguiente forma:

```
1 # Entrenar el modelo
2 history = model.fit(
3     x_train,
4     y_train,
5     validation_split=0.1,
6     epochs=epochs,
7     batch_size=batch_size,
8     verbose=1
9 )
```

Especificamos que se utilizan las particiones de entrenamiento *x_train* (las imágenes) e *y_train* (la etiqueta asociada a cada una de las imágenes del conjunto de entrenamiento). Además, con *validation_split = 0.1* indicamos que solo el 10 % de los datos se utilizarán para validar el modelo. Se especifica también el tamaño del *batch* (recordemos que lo habíamos fijado a 32) y el número de épocas (30 inicialmente). El parámetro *verbose* es solo para mostrar el progreso del entrenamiento; no tiene ningún otro fin.

Este método devuelve una historia, la cuál se almacena en la variable *history*. Esta historia contiene trazas de la evolución de los valores de la función de pérdida y de *accuracy* en los conjuntos de entrenamiento y de validación. Para este caso, hemos obtenido los siguientes resultados:

Figura 2: Historia del modelo *BaseNet*.

Podemos ver que no se produce *overfit*, ya que a medida que el valor del error o de la función de pérdida va bajando en el conjunto de entrenamiento, también lo hace en el de validación, hasta que llega a las últimas épocas, donde dicho valor se queda más o menos se queda un poco por encima del de entrenamiento, pareciendo que se estanca. En ningún momento el error en validación llega a subir. Si esto hubiese sucedido, podríamos haber afirmado de forma clara que se ha producido *overfit* en nuestro modelo. Si miramos también la *accuracy*, podemos ver que, a medida que va subiendo dicho valor en el conjunto de entrenamiento, también lo hace en el de validación. Aquí de nuevo sucede algo como en el caso de la función de pérdida, ya que parece que en las últimas épocas este valor se va quedando un poco estancado, aunque no dista mucho del valor obtenido en el conjunto de entrenamiento.

Sin embargo, aunque el modelo no padezca de *overfit*, sí que lo hace de *underfit*: la evolución de los valores de la función de pérdida y de la *accuracy*, aunque en un principio parecen buenos ya que el error va disminuyendo y la precisión aumentando, no es del todo satisfactoria. Podemos ver claramente como el error, aún en el conjunto de entrenamiento, sigue siendo bastante alto (en las últimas épocas se queda en torno a 1.8, valor bastante alto), y en el caso de la precisión se queda en torno a 0.45. En el caso del conjunto de validación, aunque al principio los valores sean más o menos parejos con el conjunto de entrenamiento en ambas gráficas, podemos ver como al cabo de aproximadamente unas 15-20 épocas los valores empiezan a ser dispares. En el caso de la función de pérdida, al final, los valores que se obtienen están en torno a 2, mientras que en la precisión los valores obtenidos no superan el 0.4, quedándose por debajo de los obtenidos en entrenamiento.

En líneas generales, estos resultados son demasiado pobres: lo ideal hubiese sido alcanzar un error cercano a 1 o más bajo y una precisión superior a 0.5 en el

conjunto de entrenamiento, y que los valores obtenidos en el conjunto de validación hubiesen seguido casi perfectamente a los de entrenamiento. Por tanto, de aquí podemos extraer que todavía existe mucho margen de mejora.

Es importante destacar, antes de continuar, que todos los resultados que se obtienen dependen de la ejecución. Es decir, que para dos ejecuciones puede que los resultados no sean exactamente los mismos; sin embargo, podemos decir que estarán bastante cerca, en general, ya que los datos son los mismos.

Para tener una idea de cómo de bien funciona nuestro modelo base con el conjunto de test, y para tener un valor de *accuracy* que podemos utilizar para comparar este modelo base con las mejoras futuras, vamos a hacer que prediga las etiquetas del conjunto *x_test* (las imágenes de test), y compararemos dichos valores con los reales, los cuáles están en la variable *y_test*. Para hacer dicha predicción, podemos hacerla de la siguiente forma:

```
1 # Predecir los datos
2 prediction = model.predict(
3     x_test,
4     batch_size=batch_size,
5     verbose=1
6 )
```

De esta forma, especificamos que el modelo prediga las etiquetas asociadas al conjunto *x_test* y se le especifica un tamaño de *batch*, que será el número de elementos máximos que se predigan de golpe; es decir, no se va mandar a CPU/GPU un conjunto de datos de mayor tamaño que el especificado. El parámetro *verbose* es, de nuevo, para mostrar el proceso.

El valor de *accuracy* comparando los valores predichos con los reales gira en torno a 0.4 tras realizar algunas pruebas. Dicho valor, a pesar de no ser del todo horrible para un modelo tan simple, es bastante bajo, y creemos que tiene cierto margen de mejora. ya que posiblemente, con realizar algunas modificaciones, podamos llegar una *accuracy* igual o superior a 0.5. Por tanto, vamos a intentar mejorar nuestro modelo en la próxima sección, para ver hasta dónde somos capaces de llegar.

2. MEJORA DEL MODELO

En esta sección, vamos a ir proponiendo una serie de mejoras que podemos hacer sobre el modelo. Estas mejoras son acumulativas, es decir, que se van realizando una sobre la otra, siempre y cuando ofrezcan unos buenos resultados.

Para cada caso, vamos a discutir brevemente qué es lo que se va a mejorar,

qué parámetros se van a utilizar y cuáles son los resultados obtenidos. Para cada experimento mostraremos gráficas, igual que las que se pueden ver en la figura 2.

Una vez que hayamos encontrado un modelo bueno (es decir, uno que no sufre ni de *overfit* ni de *underfit*, y ofrece unos valores de error y precisión razonables en el conjunto de validación), utilizaremos el conjunto de test para ver cómo de bien lo hace, y es entonces cuando podremos comparar dichos resultados con el modelo base, para poder ver hasta dónde hemos llegado. En ningún otro caso utilizaremos dicho conjunto, ya que no es buena idea dejarnos llevar por los resultados obtenidos en test para decir que un modelo es mejor que otro; para eso tenemos el conjunto de validación.

2.1. Normalización de los datos

La primera mejora que vamos a introducir es la normalización de los datos de entrada, haciendo que éstos tengan media $\mu = 0$ y desviación típica $\sigma = 1$. Se introduce esta mejora porque se sabe que gracias a la normalización se pueden obtener unos mejores resultados, además de que el entrenamiento de la red se puede llegar a acelerar.

La manera más fácil de normalizar los datos es utilizar un generador de la clase *ImageDataGenerator*. Para crearlo, podemos utilizar el siguiente fragmento de código:

```
1 datagen_train = ImageDataGenerator(  
2     featurewise_center=True,  
3     featurewise_std_normalization=True,  
4     validation_split=0.1  
5 )
```

De esta forma, creamos un generador para los datos de entrenamiento, el cuál hará que la media sea 0 (con el parámetro *featurewise_center = True*), normalizará la desviación típica (con el parámetro *featurewise_std_normalization = True*) y creará una partición de validación con el 10% de los datos de entrenamiento (parámetro *validation_split = 0.1*).

Como el generador utiliza normalización, hace falta entrenarlo con los datos de entrenamiento. Esto lo podemos hacer de la siguiente forma:

```
1 # Entrenar generadores  
2 datagen_train.fit(x_train)
```

Con el generador ya entrenado, podemos obtener los iteradores que se van a utilizar a la hora de entrenar el modelo. Habrá un iterador para el conjunto de

entrenamiento y otro para el conjunto de validación. Obtener estos iteradores se puede hacer de la siguiente forma:

```
1 # Crear flow de entrenamiento y validacion
2 train_iter = datagen_train.flow(
3     x_train,
4     y_train,
5     batch_size=batch_size,
6     subset='training',
7 )
8
9 validation_iter = datagen_train.flow(
10    x_train,
11    y_train,
12    batch_size=batch_size,
13    subset='validation',
14 )
```

En el primer caso, creamos un iterador de entrenamiento, utilizando para ello los datos de *x_train* e *y_train*. Es aquí donde especificamos el tamaño del *batch* (recordemos que se ha establecido que sea 32), y se indica que los datos pertenecen al subconjunto de *training* (esto es porque se ha especificado en el generador que se utilice *validation_split = 0.1*). Para el conjunto de validación el proceso es casi igual, solo que el subconjunto del que se extraerán los datos es *validation*.

Es importante destacar que a la hora de crear los iteradores (al llamar a los métodos *flow*), los datos son barajados (por defecto el parámetro *shuffle* está puesto a **True**). Esto es importante, ya que si no, Keras solo cogería el primer 10 % de los datos como validación, lo cual puede hacer que el conjunto de validación no represente para nada al conjunto de entrenamiento, y por tanto, los resultados obtenidos en validación sean pésimos.


Una vez hecho esto, ya podemos entrenar el modelo. Como en este caso utilizamos generadores, no podemos utilizar el método *fit()* tal y como hicimos anteriormente, si no que tendremos que utilizar el método *fit_generator()*. El entrenamiento que se ha realizado se puede ver en el siguiente fragmento de código:

```
1 history = model.fit_generator(
2     train_iter,
3     steps_per_epoch=len(x_train)*0.9/batch_size,
4     epochs=epochs,
5     validation_data=validation_iter,
6     validation_steps=len(x_train)*0.1/batch_size
7 )
```


Especificamos que para entrenar se va a utilizar el iterador *train_iter* creado anteriormente. Por cada época se van a realizar *len(x_train) * 0.9/batch_size* pasos (esto es, del tamaño del conjunto de entrenamiento original se cogerá el 90 % de dicho tamaño, que representa el porcentaje de datos que se utilizarán para

entrenar, y este número de elementos se dividirá entre el tamaño del *batch*, que es 32; de esta forma se sabe cuántos pasos hay que dar para el tamaño de *batch* especificado). Luego se indica cuántas épocas se quieren entrenar (de momento, viendo los resultados que se han obtenido en el apartado anterior, vamos a conservar su valor anterior, que es 35, ya que no se produce un *overfit* que nos indique que haga falta rebajar dicho número). Se indica que como datos de validación se va a utilizar el *validation_iter* creado anteriormente y se indica el número de pasos que se van a hacer a la hora de validar, lo cuál se hace de forma similar a cómo se hizo con el conjunto de entrenamiento, solo que se utilizará el 10 % del tamaño del conjunto de entrenamiento.

Con el entrenamiento ya hecho, vamos a estudiar las gráficas para ver qué tal ha ido:



(a) Evolución de la función de pérdida.



(b) Evolución de la *accuracy*.

Figura 3: Historia del modelo *BaseNet* con normalización.

Como podemos ver, comparando los resultados con los que se pueden ver en la figura 2 los valores de pérdida son menores en el conjunto de entrenamiento que los que teníamos anteriormente. Además, el valor de *accuracy* es más alto que el que habíamos obtenido en el caso anterior para el el conjunto de entrenamiento. Sin embargo, si estudiamos los resultados obtenidos en validación, vemos que no ha habido ninguna mejora significativa, ya que los resultados son bastante parecidos a los que teníamos anteriormente.

Además de eso, si estudiamos los valores de entrenamiento y de validación de forma conjunta, podemos ver que, a diferencia de lo que sucedía en la figura 2, aquí los resultados en validación se quedan mucho más cortos cuando llegamos a las últimas épocas. Al principio, los valores van bastante pegados, pero a medida que aumentan el número de épocas, éstos se van despegando, hasta llegar al resultado final que podemos ver en las gráficas de la figura 3.

En líneas generales podemos ver que los valores de la función de pérdida en validación se quedan bastante por encima de los de entrenamiento, y la *accuracy* se queda bastante por debajo de la de entrenamiento. Aparte, en ambos parece que se estanca en las últimas épocas, mientras que los valores obtenidos en entrenamiento siguen mejorando. Por tanto, podemos detectar cierto *overfit*, ya que aunque se mejore en entrenamiento, no hay mejoras reales en validación, con lo cuál parece que el modelo está comenzando a memorizar los datos de entrenamiento. Posiblemente, de haber entrenado algunas épocas más, los valores de validación hubiesen empezado a empeorar.

Tras este breve análisis podemos ver que, a pesar de que normalizar ha permitido mejorar los resultados obtenidos en entrenamiento, los de validación aún se quedan muy cortos. Por tanto, ha habido cierta mejora, pero no significativa. Esto puede deberse a que solo se normaliza la entrada, y a media que se van haciendo convoluciones, dicha normalización se pierde. Con lo cuál, parece lógico que se tengan que introducir capas de normalización en la red para que los datos siempre estén normalizados, aunque esto lo haremos más adelante. De momento, conservaremos la normalización, ya que es una mejora que siempre ayuda y, si conseguimos combinarla con alguna otra mejora, puede que los resultados sean bastante mejores.

2.2. Aumento de datos

La siguiente mejora que podemos probar es el aumento de datos. De esta forma, a partir de los datos que tenemos para entrenar el modelo, podemos generar nuevos datos aplicándoles transformaciones, como por ejemplo rotaciones, zoom, espejo, etc. Para estudiar si existe mejora al aplicar esta técnica, vamos a probar una serie de transformaciones que utilizaremos en combinación con la normalización, ya que siempre es útil normalizar los datos de entrada. Las transformaciones a probar son las siguientes:

- **Flip horizontal.** Este aumento consiste en voltear la imagen en el eje horizontal. Puede ser una mejora interesante debido a que va a invertir la imagen, y por ende los elementos de la imagen, con lo cuál podemos llegar a tener la imagen normal en alguna de las épocas de entrenamiento, y la imagen volteada en otra, la cuál será tratada como una nueva muestra de entrenamiento. Por tanto, es posible que ayude a generalizar mejor.
- **Zoom.** Este aumento consiste en realizar un zoom sobre la imagen, tanto para alejarse de ella como para acercarse. Podría ser interesante aplicar este aumento ya que nos podría ofrecer información sobre una misma imagen a distintas escalas, desde más cerca o más lejos por ejemplo.

- **Rotación.** Este aumento rota la imagen en α grados en cualquiera de los dos sentidos. Es un aumento que puede ser útil cuando la imagen no ha sido tomada en condiciones óptimas (por ejemplo, con algún tipo de rotación, haciendo que los objetos estén de lado). De esta forma, se puede aprender más mirando un mismo objeto con distintas orientaciones.
- ***Flip* horizontal + zoom.** Esta es una mejora que combina tanto el *flip* com el zoom, con el objetivo de ver si al invertir la imagen y hacer zoom se puede aprender más, y por tanto, generalizar mejor, ya que se tienen nuevos elementos en el conjunto de entrenamiento a distintas escalas.

Ya que en este apartado vamos a generar nuevas imágenes, podemos probar a aumentar el número de épocas de 35 a 50, ya que con pocas épocas no se va a notar nada el aumento. Esto se debe a que los aumentos se generan sobre la marcha, y tienen una probabilidad de aparecer o no. Con lo cuál, podría darse la mala suerte de que no salgan muchos aumentos en pocas épocas, y entonces es como si estuviésemos entrenando con los datos normales. Además, así podremos ver si al insertar nuevos datos y aumentar el número de épocas, podemos disminuir un poco el *overfit* que se producía, tal y como se puede ver en la figura 3.

Antes de ver los resultados que ofrece cada uno de estos aumentos, hace falta conocer cómo se hacen los aumentos. Gracias a la clase *ImageDataGeneratos* podemos hacerlo de forma bastante sencilla, ya que podemos especificar qué aumentos queremos hacer (recordemos que también vamos a especificar que se normalicen los datos y que vamos a crear una partición de validación).

Para especificar que queremos hacer un ***flip* horizontal**, además de aplicar normalización y crear un conjunto de validación, podemos hacerlos de la siguiente forma:

```
1 # Datagen con flip horizontal
2 datagen_train_flip = ImageDataGenerator(
3     featurewise_center=True,
4     featurewise_std_normalization=True,
5     validation_split=0.1,
6     horizontal_flip=True
7 )
```

Lo único diferente a lo que hacíamos anteriormente es especificar el parámetro *horizontal_flip* poniéndolo a **True**.

Podemos declarar un generador con **zoom** de la siguiente forma:

```
1 # Datagen con zoom de 0.2
2 datagen_train_zoom = ImageDataGenerator(
3     featurewise_center=True,
4     featurewise_std_normalization=True,
```

```
5     validation_split=0.1,  
6     zoom_range=0.2  
7 )
```

El parámetro *zoom_range* controla la escala del zoom, tanto para alejarse como para acercarse de la imagen. En este caso, se ha especificado que dicho valor sea 0.2, un valor no muy grande y que es comunmente.

Para declarar un generador que utilice **rotación**, podemos utilizar algo como lo que se ve a continuación:

```
1 # Datagen con rotacion de 25  
2 datagen_train_rot = ImageDataGenerator(  
3     featurewise_center=True,  
4     featurewise_std_normalization=True,  
5     validation_split=0.1,  
6     rotation_range=25  
7 )
```

La rotación se especifica con el parámetro *rotation_range*. En este caso, se ha especificado que se rote como máximo 25° en cualquiera de los dos sentidos. Se ha escogido este valor porque se cree que es razonable que se realicen pequeñas rotaciones sobre la imagen en vez de rotaciones muy abruptas.


Finalmente, podemos crear un generador que combine **flip horizontal** junto con **zoom** de la siguiente forma:

```
1 # Datagen con flip horizontal y zoom de 0.2  
2 datagen_train_fz = ImageDataGenerator(  
3     featurewise_center=True,  
4     featurewise_std_normalization=True,  
5     validation_split=0.1,  
6     horizontal_flip=True,  
7     zoom_range=0.2  
8 )
```



Aquí no hay nada nuevo que comentar, ya que es una combinación de dos de los generadores vistos anteriormente.

Para utilizar los generadores, de nuevo tenemos que utilizar el método *fit()* tal y como hicimos antes, además de crear los iteradores correspondientes. Para entrenar el modelo, de nuevo podemos utilizar el método *fit_generator()*.

Una vez comentados los aspectos generales, vamos a analizar los resultados obtenidos para cada tipo de aumento de datos, comparándolos con lo que teníamos anteriormente y entre ellos, y decidiendo cuál es el mejor para este problema.



(a) Evolución de la función de pérdida.

(b) Evolución de la *accuracy*.Figura 4: Historia del aumento de datos con *flip* horizontal.

(a) Evolución de la función de pérdida.



(b) Evolución de la *accuracy*.

Figura 5: Historia del aumento de datos con zoom.



(a) Evolución de la función de pérdida.


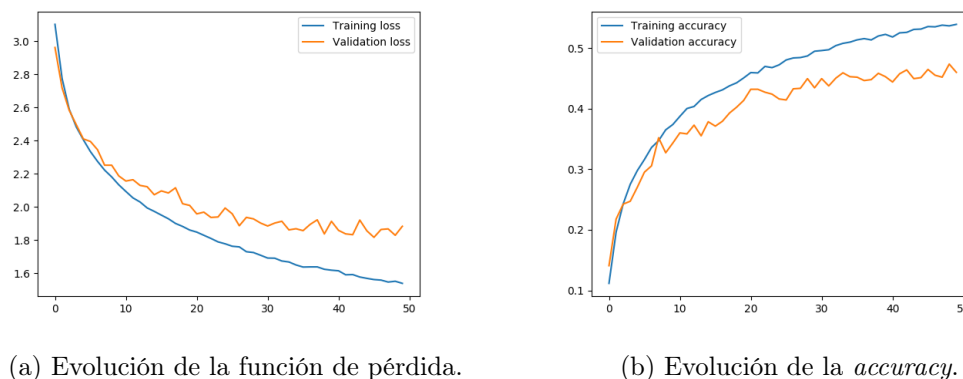
(b) Evolución de la *accuracy*.

Figura 6: Historia del aumento de datos con rotación.



(a) Evolución de la función de pérdida.

(b) Evolución de la *accuracy*.Figura 7: Historia del aumento de datos con *flip* horizontal y zoom.

En general, si miramos los resultados, podemos ver que hay aumentos de datos, como por ejemplo el zoom y la rotación que no aportan casi ninguna mejora, ya que los resultados obtenidos para entrenamiento son bastante buenos, mientras que en validación se queda bastante corto, tanto en las gráficas de error como en la de *accuracy*. El error en validación se queda, en ambos casos, muy cerca de 2, mientras que el de entrenamiento baja hasta 1.5-1.6. La *accuracy* en validación se queda en torno a 0.4 en validación, mientras que en entrenamiento supera los 0.5 en ambos casos. Estos resultados recuerdan mucho a los que se pueden ver en la figura 3, y por tanto, no representan una mejora suficiente como para volver a utilizarlos en el futuro.

En cambio, si comparamos los resultados obtenidos para los casos en los que se utiliza *flip* horizontal, vemos que sí que se produce cierta mejora respecto a los modelos anteriores, y a los otros modelos con aumentos de zoom y rotación. En los dos modelos que se usa el *flip* horizontal el error en validación se sitúa por debajo de 2, mejorando por tanto los resultados obtenidos por el modelo base y por el modelo con solo la normalización. La *accuracy* en validación también ha sufrido un ligero incremento, situándose en ambos casos por encima de 0.4. Por tanto, el modelo mejora ciertamente al utilizar *flip* horizontal.

Ahora bien, si comparamos ambos modelos, vemos que en el caso en el que solo se hace el *flip*, los valores en validación son un poco mejores que los obtenidos al aumentar los datos con *flip* y zoom. Sin embargo, en este segundo caso, los resultados de validación se quedan más cerca de los de entrenamiento. Por tanto, en el segundo caso, se podría decir que se está generalizando mejor, a pesar de que los resultados son, en general, un poco peores. A pesar de eso, parece que en ambos modelos las curvas de validación se van a estancar en unas pocas épocas más, mientras que las de entrenamiento continuarán mejorando. Por tanto, ninguno de los dos modelos está libre de potencial *overfit*.

Si nos basamos en como de bien se puede generalizar, la opción clara, de momento, sería escoger como mejor aumento de datos el que realiza un *flip* junto con un zoom. Sin embargo, si nos atendemos a los resultados obtenidos en validación, el mejor es el que hace solo el *flip*. Como el modelo puede ser regularizado para reducir el *overfit*, vamos a escoger como **mejor aumento** el que **solo realiza un *flip* horizontal** por habernos ofrecido unos mejores resultados en validación.

2.3. Aumento de la profundidad de la red

La siguiente mejora que nos podemos plantear es aumentar la profundidad de la red. Para ello, se van a proponer dos arquitecturas. Ambas se compararán, y se elegirá la mejor. En un principio, ambas se compararán solo con la normalización, y después se mirará como son afectadas por el aumento de datos con *flip* horizontal (el aumento que mejores resultados ha proporcionado).

Ambos modelos están compuestos por dos módulos convolucionales, cada uno con dos capas convolucionales, y una capa de *max pooling* al final. Además, en ambos modelos se ha pasado a tener 3 capas totalmente conectadas, formando una red de $128 \times 50 \times 25$ neuronas que se encargarán de clasificar según la información extraída por la red convolucional, y en los dos modelos el número de canales va creciendo a medida que se van haciendo convoluciones. Al tener una arquitectura como esta, no se reduce el tamaño de las imágenes tan rápidamente como pasaba antes, ya que antes de cada *max pool* hay dos convoluciones en vez de una.

A pesar de las similitudes que tienen los dos modelos, existen dos diferencia importante entre ellos: el tamaño del *kernel* de las convoluciones y el número de canales de salida:

- En el caso de la primera red, el primer módulo convolucional está compuesto por dos convoluciones 5×5 , con 8 y 16 canales de salida, respectivamente. El segundo módulo está compuesto por dos capas convolucionales con *kernel* de tamaño 3×3 , y con 32 y 64 canales de salida.
- En la segunda red los dos módulos utilizan convoluciones de tamaño 3×3 , y el número de canales es 16 y 32 para el primer módulo convolucional y de 64 y 64 para el segundo módulo.

En el primer modelo, las convoluciones del primer módulo se han hecho así para imitar las que hace *BaseNet*, solo que se ha cambiado el número de canales de salida de la primera convolución. Las del segundo módulo tienen un tamaño de 3×3 para no reducir demasiado la imagen, además de que las convoluciones de este tamaño son más rápidas que las 5×5 . El número de canales de salida es siempre

una potencia de 2. No hay ningún motivo para que sea un número potencia de 2, ya que la red no va a obtener mejores resultados por tener canales de salida de tamaño potencia de 2.

En el segundo modelo, todas las convoluciones son de 3×3 porque son menos costosas desde el punto de vista computacional. Todos los canales de salida de las capas convolucionales son, de nuevo, potencias de 2. Sin embargo, a diferencia del modelo anterior, el número de canales de la primera capa convolucionada es de 16, y se incrementa hasta un máximo de 64, ya que se cree que no tiene sentido hacer canales más grandes debido a que éstos pueden llevar a un *overfit* excesivo sin regularizar.

Una vez que hemos comentado los aspectos generales de ambas arquitecturas, vamos a ver cómo sería la implementación de ellas. El código correspondiente al primer modelo es el siguiente:

```
1 # Definicion del nuevo modelo
2 model_v2 = Sequential()
3 model_v2.add(Conv2D(8, kernel_size=(5, 5), padding='valid',
4     input_shape=input_shape))
5 model_v2.add(Activation('relu'))
6 model_v2.add(Conv2D(16, kernel_size=(5, 5), padding='valid'))
7 model_v2.add(Activation('relu'))
8 model_v2.add(MaxPooling2D(pool_size=(2, 2)))
9
10 model_v2.add(Conv2D(32, kernel_size=(3, 3), padding='valid'))
11 model_v2.add(Activation('relu'))
12 model_v2.add(Conv2D(64, kernel_size=(3, 3), padding='valid'))
13 model_v2.add(Activation('relu'))
14 model_v2.add(MaxPooling2D(pool_size=(2, 2)))
15
16 model_v2.add(Flatten())
17 model_v2.add(Dense(units=128))
18 model_v2.add(Activation('relu'))
19 model_v2.add(Dense(units=50))
20 model_v2.add(Activation('relu'))
21 model_v2.add(Dense(units=25))
22 model_v2.add(Activation('softmax'))
```

El segundo modelo se ha declarado de la siguiente forma:

```
1 # Definicion del nuevo modelo
2 model_v3 = Sequential()
3 model_v3.add(Conv2D(16, kernel_size=(3, 3), padding='valid',
4     input_shape=input_shape))
5 model_v3.add(Activation('relu'))
6 model_v3.add(Conv2D(32, kernel_size=(3, 3), padding='valid'))
7 model_v3.add(Activation('relu'))
8 model_v3.add(MaxPooling2D(pool_size=(2, 2)))
9
10 model_v3.add(Conv2D(64, kernel_size=(3, 3), padding='valid'))
```

```


10 model_v3.add(Activation('relu'))
11 model_v3.add(Conv2D(64, kernel_size=(3, 3), padding='valid'))
12 model_v3.add(Activation('relu'))
13 model_v3.add(MaxPooling2D(pool_size=(2, 2)))
14
15 model_v3.add(Flatten())
16 model_v3.add(Dense(units=128))
17 model_v3.add(Activation('relu'))
18 model_v3.add(Dense(units=50))
19 model_v3.add(Activation('relu'))
20 model_v3.add(Dense(units=25))
21 model_v3.add(Activation('softmax'))

```


Una vez compilados los modelos, vamos a entrenarlos y a ver los resultados que obtenemos. Es importante destacar que, para entrenar estos modelos, el número de épocas ha sido reducido a 35. De esta forma, si los modelos tardan más en entrenarse, no se realizan tantas épocas, y por tanto el tiempo de entrenamiento es menor. Además, como vimos en la sección anterior, al haber entrenado 50 épocas, los modelos estaban muy cerca de padecer de sobreajuste, con lo cual parece sensato reducir el número de épocas para intentar evitar que esto suceda para estos nuevos modelos.

Otra cosa importante a destacar es que primero se entrenarán los modelos utilizando solo la normalización. Posteriormente, si todo va bien, entrenaremos con aumento de datos, aplicando un *flip* horizontal sobre las imágenes, y miraremos si existe mejora.

Una vez comentado estos detalles, vamos a pasar a estudiar los resultados obtenidos.




(a) Evolución de la función de pérdida.



(b) Evolución de la *accuracy*.

Figura 8: Historia del primer modelo profundo.



(a) Evolución de la función de pérdida.


(b) Evolución de la *accuracy*.

Figura 9: Historia del segundo modelo profundo.

Se puede observar a simple vista que los resultados obtenidos son muy malos. En ambos casos, el *overfit* es evidente, ya que los valores del error en validación empiezan a subir a partir de las 15 épocas, mientras que los valores del error en entrenamiento sigue constante. Esto también se refleja en las gráficas de *accuracy*, donde podemos ver que la precisión en el conjunto de entrenamiento va mejorando, mientras que la del conjunto de validación se queda estancada y no mejora nada. Toda esta situación llevará a que la red no sea capaz de generalizar correctamente, ya que al existir sobreajuste, la red acaba memorizando los datos de entrenamiento, y obtendrá unos resultados pésimos con nuevos datos que nunca antes ha visto.

Este problema se debe a que hemos aumentado la profundidad de la red, y con eso, el número de parámetros de la red. Estos parámetros pueden tomar cualquier valor, ya que no hay ninguna restricción sobre ellos. Cuando sucede esto, los parámetros se pueden “descontrolar”, tomando valores que le permiten ajustarse más a los datos de entrenamiento, y por tanto, disminuir el error en el conjunto de entrenamiento, ya que es lo que se está intentando minimizar. Esto nos llevará a unos resultados como los que podemos ver en las figuras 8 y 9, donde los resultados en el conjunto de entrenamiento son muy buenos mientras que los de validación son muy malos.

Este problema puede ser difícil de solventar, ya que no hay una única manera de intentar reducir el *overfit*. Una idea simple sería aplicar *early stopping*, parando el entrenamiento antes de que empiece a sobreajustar. En este caso, sería parar el entrenamiento alrededor de las 10-15 épocas. Sin embargo, si hacemos eso, el modelo que obtendremos será bastante malo, ya que no habrá aprendido lo suficiente debido a que los valores del error y la precisión serán bastante malos en general (como podemos ver en las gráficas). Por tanto, para solventar este problema podemos probar a utilizar una técnica de regularización como **Dropout**, la cuál procederemos a ver a continuación.

2.4. Mejora extra: regularización mediante Dropout

La forma más sencilla de regularizar nuestros modelos es el **Dropout**. Este proceso consiste en escoger una proporción de las neuronas de una capa de forma aleatoria y en desactivar las conexiones de dichas neuronas con las neuronas de la capa siguiente, de forma que no participan en el proceso. Luego, a la hora de predecir, no se realiza Dropout, ya que participan todas las conexiones. En cambio, los valores predichos son ponderados en función del número de veces que esa conexión se haya dejado activa. Está demostrado que, en general, este proceso ayuda a reducir el *overfit*, y por tanto, hace que la red sea capaz de generalizar mejor. Sin embargo, como cualquier método de regularización, hace falta usarlo con cuidado, ya que insertar demasiadas capas de Dropout puede llevar a una regularización excesiva del modelo, y por tanto, que el modelo sufra de *underfitting*, ya que los valores que pueden tomar los parámetros se habrán limitado en exceso.

Para regularizar nuestros modelos, vamos a insertar una capa de Dropout después de cada módulo convolucional (recordemos que un módulo está formado por un conjunto de capas **Convolución-Convolución-Max Pooling**). No existe como tal una regla de oro que nos diga dónde insertar las capas de Dropout, ya que eso depende mucho del modelo. En este caso se ha decidido poner una capa de Dropout al final de cada módulo convolucional porque se considera que el sobreajuste viene a raíz de pasar de un módulo convolucional a otro debido a que al final de uno se reduce la imagen a la mitad, y al principio del siguiente se aplican convoluciones para extraer características. Al tener imágenes tan pequeñas en general, los tamaños se reducen muy rápido, con lo cual, al tener convoluciones que producen salidas bastante grandes, se empiezan a extraer características muy particulares de dichas imágenes, lo que al final provoca que se acaben memorizando los datos de entrenamiento. Al regularizar no se deja que se entrenen todos los parámetros de la red a la vez, sino solo una parte. De esta forma, se llega a evitar el problema comentado anteriormente.

Cuando insertemos capas de Dropout, hace falta especificar la proporción de conexiones que vamos a desactivar. En algunos artículos se aconseja que si se utiliza Dropout en la red convolucional (no en las capas totalmente conectadas) que la proporción de conexiones que se desactiven sea pequeña [2]. Por tanto, siendo p la proporción de conexiones a desactivar, vamos a hacer que $p = 0.2$. De esta forma, estamos desactivando un número de conexiones pequeño, pero aún así suficiente para regularizar la red.

Con esto comentado, vamos a ver cómo quedarían los dos modelos anteriores aplicando Dropout. El código que define la arquitectura del primer modelo, al que llamaremos *Modelo A*, se puede ver a continuación:

```
1 # Definición del nuevo modelo
2 model_v2 = Sequential()
```

```

3 model_v2.add(Conv2D(8, kernel_size=(5, 5), padding='valid',
4   input_shape=input_shape))
5 model_v2.add(Activation('relu'))
6 model_v2.add(Conv2D(16, kernel_size=(5, 5), padding='valid'))
7 model_v2.add(Activation('relu'))
8 model_v2.add(MaxPooling2D(pool_size=(2, 2)))
9 model_v2.add(Dropout(0.2))
10 model_v2.add(Conv2D(32, kernel_size=(3, 3), padding='valid'))
11 model_v2.add(Activation('relu'))
12 model_v2.add(Conv2D(64, kernel_size=(3, 3), padding='valid'))
13 model_v2.add(Activation('relu'))
14 model_v2.add(MaxPooling2D(pool_size=(2, 2)))
15 model_v2.add(Dropout(0.5))
16
17 model_v2.add(Flatten())
18 model_v2.add(Dense(units=128))
19 model_v2.add(Activation('relu'))
20 model_v2.add(Dense(units=50))
21 model_v2.add(Activation('relu'))
22 model_v2.add(Dense(units=25))
23 model_v2.add(Activation('softmax'))

```

El segundo modelo, al que llamaremos *Modelo B*, introduciendo regularización, se puede representar de la siguiente manera:

```


1 # Definicion del nuevo modelo
2 model_v3 = Sequential()
3 model_v3.add(Conv2D(16, kernel_size=(3, 3), padding='valid',
4   input_shape=input_shape))
5 model_v3.add(Activation('relu'))
6 model_v3.add(Conv2D(32, kernel_size=(3, 3), padding='valid'))
7 model_v3.add(Activation('relu'))
8 model_v3.add(MaxPooling2D(pool_size=(2, 2)))
9 model_v3.add(Dropout(0.2))
10 model_v3.add(Conv2D(64, kernel_size=(3, 3), padding='valid'))
11 model_v3.add(Activation('relu'))
12 model_v3.add(Conv2D(64, kernel_size=(3, 3), padding='valid'))
13 model_v3.add(Activation('relu'))
14 model_v3.add(MaxPooling2D(pool_size=(2, 2)))
15 model_v3.add(Dropout(0.5))
16
17 model_v3.add(Flatten())
18 model_v3.add(Dense(units=128))
19 model_v3.add(Activation('relu'))
20 model_v3.add(Dense(units=50))
21 model_v3.add(Activation('relu'))
22 model_v3.add(Dense(units=25))
23 model_v3.add(Activation('softmax'))

```


Estos modelos tienen que ser compilados y entrenados de la misma forma que

hemos visto antes. Utilizaremos de nuevo 35 épocas, para comparar si ha habido mejora al utilizar regularización respecto a los resultados que hemos obtenido anteriormente. De nuevo, de momento solo utilizaremos normalización al utilizar los generadores. Si existe mejora, probaremos a utilizar el generador que utiliza aumento de datos de *flip* horizontal.

A continuación podemos ver las gráficas obtenidas para ambos modelos:




(a) Evolución de la función de pérdida.




(b) Evolución de la *accuracy*.

Figura 10: Historia del *Modelo A*.



(a) Evolución de la función de pérdida.



(b) Evolución de la *accuracy*.

Figura 11: Historia del *Modelo B*.


Si comparamos estas gráficas con las figuras 8 y 9, podemos ver que los modelos han mejorado un montón. Ahora en ambos los resultados obtenidos en validación se parecen mucho más a los de entrenamiento, ya que en ambos casos, las curvas van más pegadas. Además, se ha eliminado completamente el *overfit*, ya que los resultados obtenidos en validación van mejorando a medida que los de entrenamiento mejoran. Podemos ver claramente que en las gráficas de la evolución del error no se

produce un incremento en validación en las últimas épocas, cosa que sí que sucedía en los casos anteriores.


Ahora, si analizamos los resultados, podemos ver que en general son muy buenos. El error en ambos casos se sitúa por debajo de 2, y la precisión está por encima de 0.4, tal y como pasaba con los resultados que se pueden ver en la figura 4, aunque en este caso son mejores, ya que no hay sobreajuste. En general, los resultados obtenidos por el *Modelo B* en validación son mejores debido a que el error en validación es menor y la *accuracy* es mayor. Además, los valores obtenidos para el conjunto de entrenamiento son bastante parejos, y son bastante mejores que los obtenidos en el *Modelo A*.

Ya que los resultados obtenidos con 35 épocas han sido bastante buenos, vamos a subir de nuevo el número de épocas a 50, para ver si se pueden mantener al entrenar los modelos durante más épocas. Que suceda esto sería lo ideal, ya que, al entrenar más, podríamos tener un modelo que generalice mejor, siempre y cuando los resultados obtenidos en validación sigan el mismo comportamiento que los obtenidos anteriormente.

Por tanto, restablecemos los pesos de los modelos y los entrenamos de nuevo. Los resultados obtenidos se pueden ver a continuación:




(a) Evolución de la función de pérdida.




(b) Evolución de la *accuracy*.

Figura 12: Historia del *Modelo A*.




(a) Evolución de la función de pérdida.


(b) Evolución de la *accuracy*.Figura 13: Historia del *Modelo B*.

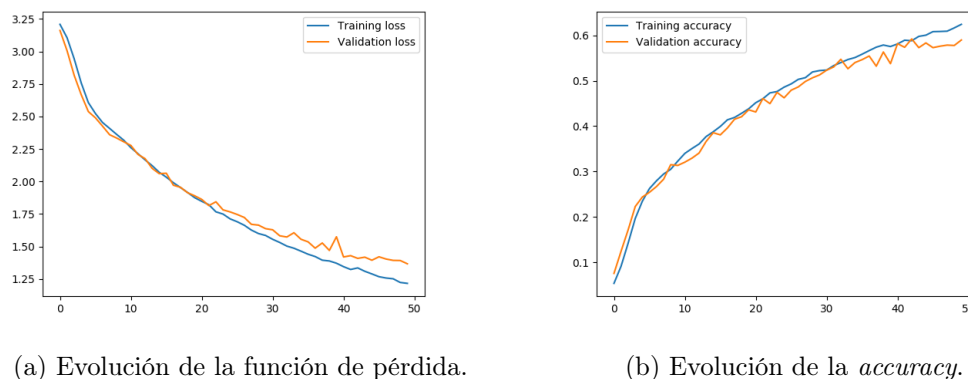
Podemos ver que, en general, al haber aumentado el número de épocas, los valores de validación han mejorado en ambos modelos tanto para los valores de la función de pérdida como para la *accuracy*. En general, para el *Modelo A*, los resultados obtenidos en validación están más pegados a los valores de entrenamiento que los obtenidos en el *Modelo B*. No obstante, los obtenidos en el *Modelo B* son mucho mejores que los obtenidos en el *Modelo A*, tanto en validación como en entrenamiento. Es en este modelo donde, por primera vez, se consigue una *accuracy* en validación superior al 0.5, lo cuál son buenas noticias, ya que hemos conseguido mejorar bastante el modelo base, el cuál no llegaba ni al 0.4, tal y como se puede ver en la figura 2. Así que, en general, aumentar el número de épocas ha sido una buena idea.

Para elegir el mejor modelo, vamos a probar a entrenar ambos modelos con aumento de datos, para ver cuál se comporta mejor. Las gráficas obtenidas son las siguientes:



(a) Evolución de la función de pérdida.

(b) Evolución de la *accuracy*.Figura 14: Historia del *Modelo A*.



(a) Evolución de la función de pérdida.

(b) Evolución de la *accuracy*.Figura 15: Historia del *Modelo B*.

En ambos casos los resultados son muy buenos, siendo incluso mejores que los que obtuvimos utilizando solo la normalización. Podemos ver aquí cómo los resultados obtenidos en el conjunto de validación en ambos modelos se ajustan mejor a los obtenidos en entrenamiento que antes. Además, en este caso, la *accuracy* obtenida con el *Modelo A* en las últimas épocas llega al 0.5, superando a la que tenía anteriormente. Por tanto, introducir aumento de datos ha mejorado significativamente los resultados obtenidos en el *Modelo A*.

En el caso del *Modelo B*, podemos ver como el error en validación se ve reducido más aún, y la *accuracy* comienza a acercarse a 0.6. Además, el error obtenido en este caso es bastante menor que el del *Modelo A*. Si observamos el error en entrenamiento, podemos ver que en este caso es mayor que el que se ve en la figura 13, aunque esto no nos preocupa mucho, ya que en validación obtiene mejores resultados.

Por tanto, como veredicto final, vamos a quedarnos con el *Modelo B*, ya que es el que ha obtenido unos mejores resultados en el conjunto de validación y, además, no presenta *overfit*. Por tanto, hemos conseguido crear una arquitectura más profunda que es capaz de conseguir unos buenos resultados y que, de momento, parece que es capaz de generalizar bastante bien. Veremos si con la próxima mejora somos capaces de sacar el máximo potencial al modelo.

2.5. Capas de normalización

La última mejora que queremos introducir en el modelo es la *Batch Normalization* o normalización por lotes. Esto es, se introducen algunas capas en la red que se encargan de aprender valores con los cuáles pueden transformar los datos para

intentar normalizarlos. Esta es una técnica que permite regularizar la red, reducir los tiempos de entrenamiento y obtener unos resultados mejores en general.

Se ha decidido insertar una capa de normalización después de cada capa convolucional y de cada capa totalmente conectada. De esta forma, después de cada operación, los datos serán normalizados, con lo cuál no se perderá esa normalización que se hace sobre los datos de entrada. Además, se cree que el rendimiento de la red mejorará al utilizar una normalización después de cada convolucional y totalmente conectada. Si en las gráficas se ve que se produce *underfitting* porque a lo mejor se ha regularizado demasiado, se reducirá el número de capas de normalización. No obstante, en un principio, se cree que el impacto será más bien positivo, y que permitirá a la red generalizar mejor. El único lugar donde no se pondrá normalización es después de la capa de *softmax* ya que no tiene sentido (esta capa es la salida de la red, y da probabilidades; por tanto, no tiene sentido utilizar normalización ahí).

El problema de introducir normalización viene a la hora de determinar dónde ponerla, si antes o después de la función de activación. Para ello, vamos a construir dos modelos: uno primero al que llamaremos *Modelo Pre*, donde la normalización estará antes de la función de activación; y un segundo modelo al que llamaremos *Modelo Post*, en el que la capa de normalización estará justo después de la función de activación.

El *Modelo Pre* se define de la siguiente forma:

```
1 # Definicion del nuevo modelo
2 model_batch_pre = Sequential()
3 model_batch_pre.add(Conv2D(16, kernel_size=(3, 3), padding='valid',
4                             input_shape=input_shape))
5 model_batch_pre.add(BatchNormalization())
6 model_batch_pre.add(Activation('relu'))
7 model_batch_pre.add(Conv2D(32, kernel_size=(3, 3), padding='valid'))
8 model_batch_pre.add(BatchNormalization())
9 model_batch_pre.add(Activation('relu'))
10 model_batch_pre.add(MaxPooling2D(pool_size=(2, 2)))
11 model_batch_pre.add(Dropout(0.2))
12 model_batch_pre.add(Conv2D(64, kernel_size=(3, 3), padding='valid'))
13 model_batch_pre.add(BatchNormalization())
14 model_batch_pre.add(Activation('relu'))
15 model_batch_pre.add(Conv2D(64, kernel_size=(3, 3), padding='valid'))
16 model_batch_pre.add(BatchNormalization())
17 model_batch_pre.add(Activation('relu'))
18 model_batch_pre.add(MaxPooling2D(pool_size=(2, 2)))
19 model_batch_pre.add(Dropout(0.5))
20
21 model_batch_pre.add(Flatten())
22 model_batch_pre.add(Dense(units=128))
23 model_batch_pre.add(BatchNormalization())
24 model_batch_pre.add(Activation('relu'))
```


```
25 model_batch_pre.add(Dense(units=50))
26 model_batch_pre.add(BatchNormalization())
27 model_batch_pre.add(Activation('relu'))
28 model_batch_pre.add(Dense(units=25))
29 model_batch_pre.add(Activation('softmax'))
```

La arquitectura del *Modelo Post* viene definida por el siguiente código:



```
1 # Definicion del nuevo modelo
2 model_batch_post = Sequential()
3 model_batch_post.add(Conv2D(16, kernel_size=(3, 3), padding='valid',
4                             input_shape=input_shape))
5 model_batch_post.add(Activation('relu'))
6 model_batch_post.add(BatchNormalization())
7 model_batch_post.add(Conv2D(32, kernel_size=(3, 3),
8                             padding='valid'))
9 model_batch_post.add(Activation('relu'))
10 model_batch_post.add(BatchNormalization())
11 model_batch_post.add(MaxPooling2D(pool_size=(2, 2)))
12 model_batch_post.add(Dropout(0.2))
13
14 model_batch_post.add(Conv2D(64, kernel_size=(3, 3),
15                             padding='valid'))
16 model_batch_post.add(Activation('relu'))
17 model_batch_post.add(BatchNormalization())
18 model_batch_post.add(Conv2D(64, kernel_size=(3, 3),
19                             padding='valid'))
20 model_batch_post.add(Activation('relu'))
21 model_batch_post.add(BatchNormalization())
22 model_batch_post.add(MaxPooling2D(pool_size=(2, 2)))
23 model_batch_post.add(Dropout(0.5))
24
25 model_batch_post.add(Flatten())
26 model_batch_post.add(Dense(units=128))
27 model_batch_post.add(Activation('relu'))
28 model_batch_post.add(BatchNormalization())
29 model_batch_post.add(Dense(units=50))
30 model_batch_post.add(Activation('relu'))
31 model_batch_post.add(BatchNormalization())
32 model_batch_post.add(Dense(units=25))
33 model_batch_post.add(Activation('softmax'))
```

Ahora nos resta entrenar nuestros modelos. Ya que comprobamos en la sección anterior que combinar Dropout con aumento de datos nos ofrecía unos resultados muy buenos con una regularización moderada, vamos a utilizar el mismo generador (recordemos que además de eso normaliza la entrada) para entrenar los modelos. Volveremos a utilizar 50 épocas, ya que en el caso anterior nos permitieron conseguir unos resultados muy buenos, ya que el modelo era capaz de aprender más.


A continuación podemos ver las gráficas obtenidas para cada modelo:



(a) Evolución de la función de pérdida.

(b) Evolución de la *accuracy*.Figura 16: Historia del *Modelo Pre*.

(a) Evolución de la función de pérdida.

(b) Evolución de la *accuracy*.Figura 17: Historia del *Modelo Post*.

Observando las gráficas, podemos ver claramente que los resultados que han obtenido ambos modelos en el conjunto de validación son muy buenos, ya que son casi idénticos a los obtenidos en el conjunto de entrenamiento. Podemos ver que en ambos casos existe muy poca discrepancia, ya que, a medida que los resultados mejoran en el conjunto de entrenamiento, sucede lo mismo en el conjunto de validación. Sin embargo, es importante destacar que en las últimas épocas del *Modelo Post* los resultados de validación empiezan a separarse un poco de los obtenidos en entrenamiento. En cambio, esto no sucede en el *Modelo Pre*, ya que los resultados en validación se ajustan más a los obtenidos en entrenamiento.

En general, los resultados obtenidos por estos modelos son los mejores que se han obtenido hasta ahora. En ambos casos los valores de la función de pérdida se sitúan por debajo de 1.5, y la precisión ronda aproximadamente 0.6.

Elegir el mejor modelo entre los dos puede ser difícil ya que ambos ofrecen unos excelentes resultados. No obstante, vamos a quedarnos con el **Modelo Pre**, ya que los resultados parecen ser un poco más consistentes que los obtenidos en el *Modelo Post*. Además de eso, creemos que tiene más sentido realizar la normalización antes de la función de activación RELU.

Por ejemplo, si todos los valores de salida de una capa fuesen negativos y éstos tuviesen que pasar por una función de activación como por ejemplo RELU, todos ellos serían puestos a 0, ya que en esta función lo que se hace normalmente es conservar los valores positivos y poner los negativos a 0. De esta forma, todas las conexiones estarían desactivadas, y no se podría hacer nada más. Al normalizar antes, los valores pasarán a tener media $\mu = 0$ y desviación típica $\sigma = 1$, de tal forma que habrán valores que permanezcan activos después de la función de activación, ya que tendremos valores positivos.

2.6. Ajuste del modelo final

Habiendo escogido el *Modelo Pre* como mejor modelo, ya solo nos queda ver de qué es capaz con el conjunto de test. También, si nos fijamos en los resultados que se pueden ver en 16, podemos ver que todavía hay cierto margen de mejora. Por tanto, vamos a realizar el ajuste final del modelo en un número superior de épocas. Vamos a fijar este valor a 60, ya que creemos que es un número lo suficientemente grande como para permitir sacarle todo el potencial a nuestro modelo.

Antes de entrenar de nuevo el modelo, vamos a hacer una serie de cosas. Lo primero, vamos a crear un generador de datos para el conjunto de test. Este generador solo tiene que hacer la normalización, ya que en el conjunto de test **nunca** debemos hacer aumento de datos. Por tanto, declaramos nuestro generador de la siguiente forma:

```
1 # Crear generador de test
2 datagen_test = ImageDataGenerator(
3     featurewise_center=True,
4     featurewise_std_normalization=True
5 )
```

Habiendo declarado el generador, hace falta entrenarlo. Para ello, tenemos que utilizar los datos del conjunto de entrenamiento, ya que la normalización a los datos de test debe hacerse en función de los datos con los que se ha entrenado, porque los datos de test son desconocidos para nuestro modelo. El entrenamiento del generador se lleva a cabo de la siguiente manera:

```
1 # Entrenar generador
2 datagen_test.fit(x_train)
```

Y, finalmente, antes de proceder con el ajuste final, vamos a ver cómo queda la arquitectura del modelo final:

Model: "sequential_2"

Layer (type)	Output Shape	Param #
conv2d_3 (Conv2D)	(None, 30, 30, 16)	448
batch_normalization_1 (Batch Normalization)	(None, 30, 30, 16)	64
activation_5 (Activation)	(None, 30, 30, 16)	0
conv2d_4 (Conv2D)	(None, 28, 28, 32)	4640
batch_normalization_2 (Batch Normalization)	(None, 28, 28, 32)	128
activation_6 (Activation)	(None, 28, 28, 32)	0
max_pooling2d_3 (MaxPooling2D)	(None, 14, 14, 32)	0
dropout_1 (Dropout)	(None, 14, 14, 32)	0
conv2d_5 (Conv2D)	(None, 12, 12, 64)	18496
batch_normalization_3 (Batch Normalization)	(None, 12, 12, 64)	256
activation_7 (Activation)	(None, 12, 12, 64)	0
conv2d_6 (Conv2D)	(None, 10, 10, 64)	36928
batch_normalization_4 (Batch Normalization)	(None, 10, 10, 64)	256
activation_8 (Activation)	(None, 10, 10, 64)	0
max_pooling2d_4 (MaxPooling2D)	(None, 5, 5, 64)	0
dropout_2 (Dropout)	(None, 5, 5, 64)	0
flatten_2 (Flatten)	(None, 1600)	0
dense_3 (Dense)	(None, 128)	204928
batch_normalization_5 (Batch Normalization)	(None, 128)	512
activation_9 (Activation)	(None, 128)	0
dense_4 (Dense)	(None, 50)	6450
batch_normalization_6 (Batch Normalization)	(None, 50)	200
activation_10 (Activation)	(None, 50)	0
dense_5 (Dense)	(None, 25)	1275
activation_11 (Activation)	(None, 25)	0
Total params: 274,581		
Trainable params: 273,873		
Non-trainable params: 708		

Figura 18: Arquitectura del modelo final.

Como se puede ver, es una red con bastantes parámetros para la profundidad que tiene. Aunque en un principio se ven muchas capas, solo unas pocas de ellas son las que realmente hacen operaciones sobre imágenes (solo hay 4). El resto añaden regularización al modelo o son las capas densas.

Una vez visto esto, vamos a proceder al entrenamiento final. Para hacerlo, utilizamos el generador de *flip* que habíamos definido anteriormente:


```
1 # Entrenar modelo utilizando aumento de datos
```

```


2 history = model_batch_pre.fit_generator(
3     train_iter_flip,
4     steps_per_epoch=len(x_train)*0.9/batch_size,
5     epochs=epochs,
6     validation_data=validation_iter_flip,
7     validation_steps=len(x_train)*0.1/batch_size
8 )

```

De nuevo, podemos ver la historia de este modelo, la cuál viene dada por las siguientes gráficas:



(a) Evolución de la función de pérdida.



(b) Evolución de la *accuracy*.

Figura 19: Historia del *Modelo Pre*.

Podemos ver como el ajuste es muy bueno, ya que los valores obtenidos en el conjunto de validación son casi idénticos a los obtenidos en el conjunto de entrenamiento. No hay mucha diferencia notable entre los resultados obtenidos en ambos conjuntos. Además, el valor de la función de pérdida obtenido es el más bajo hasta el momento, acercándose a 1 en las últimas épocas, y la precisión está por encima de 0.6. Aparte, vemos claramente que el modelo no padece ni de *underfit* ni de *overfit*, ya que ha sido regularizado previamente.

A la vista de los resultados obtenidos, podemos decir que el modelo tiene una muy buena capacidad de generalización, y que muy posiblemente los resultados obtenidos en el conjunto de test sean muy próximos a los obtenidos en el conjunto de validación.

Para predecir las etiquetas, podemos utilizar el método *predict_generator()* de la clase *ImageDataGenerator*. La llamada al método sería la siguiente:

```

1 # Predecir los datos
2 prediction = model_batch_pre.predict_generator(
3     datagen_test.flow(x_test, batch_size=1, shuffle=False),
4     steps=len(x_test),

```



```
5     verbose=1
6 )
```

Este método recibe un iterador del generador, al cuál se le pasa el conjunto de datos x_test , un tamaño de *batch* (en este caso es 1, ya que los elementos se van a predecir de uno en uno) y el parámetro *shuffle* a **False**, de forma que no se barajen los datos y salgan en el mismo orden (esto es importante para luego poder comparar con las etiquetas reales, ya que sino se desordenarían los datos de salida y no habría forma de comparar las etiquetas predichas a las reales). Adicionalmente, se dice que se den tantos pasos como elementos en el conjunto de test haya, y con *verbose* = 1 se solicita que se muestre el progreso.

Una vez hemos predicho las etiquetas, podemos calcular la precisión de nuestro modelo comparando los valores predichos con los reales. Para ello, nos podemos servir de la función que se nos ha proporcionado. Por tanto, se resumiría en hacer la siguiente llamada:

```
1 # Obtener accuracy de test
2 accuracy = calcularAccuracy(y_test, prediction)
```

En este caso se ha obtenido una *accuracy* de 0.664, un valor bastante elevado teniendo en cuenta de que partíamos de aproximadamente 0.4. Por tanto, ha habido una mejora de aproximadamente el 60 % en la precisión. Esto nos indica que todas las mejoras que hemos hecho han tenido su efecto, y que por tanto, hemos tomado la decisión correcta al incorporarlas al modelo.

3. TRANSFERENCIA DE MODELOS Y AJUSTE FINO CON RESNET50 PARA LA BASE DE DATOS CALTECH-UCSD

3.1. ResNet50 como extractor de características

Podemos utilizar la red ResNet50 como extractor de características aprovechando que ya ha sido entrenada y, con las características que se obtengan, entrenar un modelo simple de clasificación.

Podemos declarar el modelo ResNet50 preentrenado que utilizaremos para extraer las características de las imágenes de la siguiente manera:

```
1 # Definir el modelo ResNet50 (preentrenado en ImageNet y sin la
   ultima capa).
2 resnet50 = ResNet50(include_top=False, weights='imagenet',
3                     pooling='avg')
```

De esta forma, al poner el parámetro *include_top* a **False** se le quita al modelo que proporciona Keras la última capa, la cuál es una capa totalmente conectada que no nos interesa tener, ya que utilizaremos nuestro propio clasificador. El parámetro *weights = imagenet* indica que queremos cargar la red ya preentrenada en el conjunto de datos ImageNet. El último parámetro, *pooling = avg* indica que se va a coger la salida del último bloque convolucional y se le va a aplicar una media global. Es decir, se va a calcular la media de cada imagen, y eso será un elemento del vector de salida. Dicho vector tendrá un tamaño de 2048 posiciones, y será el vector de características que sirva de entrada a nuestro clasificador.

3.2. Ajuste fino de ResNet50

Referencias

- [1] Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal, Mikhail Smelyanskiy, and Ping Tak Peter Tang. On large-batch training for deep learning: Generalization gap and sharp minima. *CoRR*, abs/1609.04836, 2016.
- [2] Sungheon Park and Nojun Kwak. Analysis on the dropout effect in convolutional neural networks. pages 189–204, 03 2017.